


رسالة محمد

# شبکه‌های عصبی بازگشتی

Recurrent Neural Networks


# شبکه‌های عصبی بازگشتی

- شبکه‌های عصبی بازگشتی خروجی‌ها یا حالت‌های مخفی قبل را به عنوان ورودی دریافت می‌کنند
- ورودی ترکیبی شبکه در زمان  $t$  دارای اطلاعات زمانی از ورودی‌های گذشته ( $T < t$ ) است
- RNNها برای تحلیل‌های زمانی بسیار مفید هستند زیرا مقادیر میانی (حالت) می‌توانند اطلاعات مربوط به ورودی‌های گذشته را ذخیره کنند



# شبکه‌های عصبی بازگشتی

$$\begin{aligned} \mathbf{h}_3 &= f_W(\mathbf{h}_2, \mathbf{x}_3) \\ &= f_W(f_W(\mathbf{h}_1, \mathbf{x}_2), \mathbf{x}_3) \\ &= f_W(f_W(f_W(\mathbf{h}_0, \mathbf{x}_1), \mathbf{x}_2), \mathbf{x}_3) \\ &= g^{(3)}(\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3) \end{aligned}$$



# داده‌های متنی

- متن را می‌توان به عنوان دنباله‌ای از کاراکترها یا دنباله‌ای از کلمات در نظر گرفت
- یادگیری عمیق برای پردازش زبان طبیعی، شناسایی الگو است که بر روی کلمات، جملات و پاراگراف‌ها اعمال می‌شود، به همان روشی که یادگیری عمیق برای بینایی کامپیوتر، شناسایی الگوی اعمال شده روی پیکسل‌ها است
- از جمله کاربردهای آن دسته‌بندی اسناد، تحلیل احساسات نویسنده، بازشناسی نویسنده، ترجمه ماشینی، و پاسخ به پرسش (QA) است

# پردازش متن

- مانند همه شبکه‌های عصبی دیگر، مدل‌های یادگیری عمیق متن خام را ورودی نمی‌گیرند: آنها فقط با تانسورهای عددی کار می‌کنند
- بردارسازی متن:
  - تقسیم متن به کلمه‌ها، و تبدیل هر کلمه به یک بردار
  - تقسیم متن به کاراکترها، و تبدیل هر کاراکتر به یک بردار
  - استخراج n-gram ها از کلمه‌ها یا کاراکترها، و تبدیل هر n-gram به یک بردار
- n-gram ها گروه‌های دارای همپوشانی متشکل از چند کلمه یا کاراکتر متوالی هستند

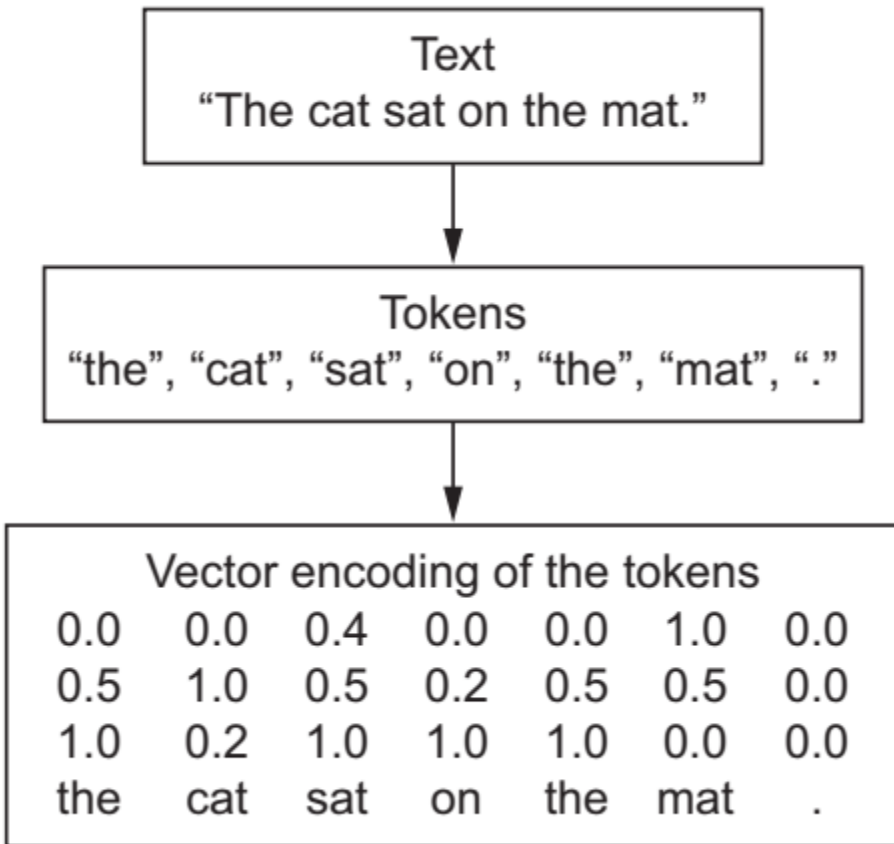
The cat sat on the mat

Bi-grams {"The cat", "cat sat", "sat on", "on the", "the mat"}

Tri-grams {"The cat sat", "cat sat on", "sat on the", "on the mat"}

# Tokenization

- واحدهای مختلفی که می‌توان متن را به آنها تجزیه کرد (کلمات، کاراکترها یا n-gram Token نامیده می‌شوند و شکستن متن به آنها Tokenization نامیده می‌شود)
- سپس برای هر Token باید یک بردار عددی در نظر گرفت



# One-hot encoding

- ابتدایی ترین راه برای تبدیل توکن به بردار است
- یک عدد صحیح منحصر به فرد به هر کلمه اختصاص می یابد و سپس این عدد صحیح  $i$  به یک بردار باینری با اندازه  $N$  (اندازه واژگان) تبدیل می شود
- همه مقادیر این بردار صفر است به جز ورودی  $i$ ام که ۱ است
- این کار در سطح کاراکتر و n-gram هم قابل انجام است





# One-hot encoding

## Listing 6.3 Using Keras for word-level one-hot encoding

```
from keras.preprocessing.text import Tokenizer
```

```
samples = ['The cat sat on the mat.', 'The dog ate my homework.']
```

```
tokenizer = Tokenizer(num_words=1000)
```

```
tokenizer.fit_on_texts(samples)
```

```
sequences = tokenizer.texts_to_sequences(samples)
```

```
one_hot_results = tokenizer.texts_to_matrix(samples, mode='binary')
```

```
word_index = tokenizer.word_index
```

```
print('Found %s unique tokens.' % len(word_index))
```

**Creates a tokenizer, configured to only take into account the 1,000 most common words**

**Turns strings into lists of integer indices**

**How you can recover the word index that was computed**

**Builds the word index**

**You could also directly get the one-hot binary representations. Vectorization modes other than one-hot encoding are supported by this tokenizer.**


# جانمایی کلمات (Word embedding)

- جانمایی کلمات اطلاعات بیشتر را در ابعاد بسیار کمتری قرار می‌دهد
- این بردارها را می‌توان با استفاده از حجم زیادی از متن پیش‌آموزش داد و در مجموعه داده‌های کوچک از آنها استفاده کرد



One-hot word vectors:

- Sparse
- High-dimensional
- Hardcoded



Word embeddings:

- Dense
- Lower-dimensional
- Learned from data

# جانمایی کلمات (Word embedding)

	Man (5391)	Woman (9853)	King (4914)	Queen (7157)	Apple (456)	Orange (6257)
↑ Gender	-1	1	-0.95	0.97	0.00	0.01
300 Royal	0.01	0.02	<u>0.93</u>	<u>0.95</u>	-0.01	0.00
Age	0.03	0.02	0.7	0.69	0.03	-0.02
Food	0.04	0.01	0.02	0.01	0.95	0.97
⋮ size cost alive verb	⋮	⋮				

e<sub>5391</sub>
e<sub>9853</sub>

Andrew Ng

# جانمایی کلمات (Word embedding)

- دو روش برای دستیابی به جانمایی کلمات وجود دارد:

- آموزش همزمان با مسئله اصلی

- مقداردهی اولیه به صورت تصادفی


- بارگذاری مقادیری که از قبل بر اساس آموزش یک مسئله دیگر بدست آمده‌اند

- جانمایی کلمات پیش‌آمخته



One-hot word vectors:

- Sparse
- High-dimensional
- Hardcoded



Word embeddings:


- Dense
- Lower-dimensional
- Learned from data

# آموزش جانمایی کلمات

- اختصاص یک بردار تصادفی به هر کلمه
  - مشکل این رویکرد این است که این فضا ساختاری ندارد
    - به عنوان مثال، کلمات **accurate** و **exact** ممکن است با جانمایی‌های کاملاً متفاوتی همراه شوند، با این وجود که در اکثر جملات قابل تعویض هستند
- روابط هندسی بین بردارهای کلمات باید منعکس‌کننده روابط معنایی بین این کلمات باشد
  - جانمایی کلمات به معنای نگاشت زبان انسان به یک فضای هندسی است
  - در یک فضای جانمایی معقول، انتظار می‌رود کلمات مترادف دارای مقادیر مشابهی باشند

# آموزش جانمایی کلمات

- انتظار می‌رود فاصله هندسی بین هر دو بردار کلمه با فاصله معنایی بین کلمات مرتبط باشد
- همچنین، انتظار می‌رود جهت‌های مختلف در فضای آموخته شده معنادار باشند




# آموزش جانمایی کلمات

- انتظار می‌رود فاصله هندسی بین هر دو بردار کلمه با فاصله معنایی بین کلمات مرتبط باشد
- همچنین، انتظار می‌رود جهت‌های مختلف در فضای آموخته شده معنادار باشند
- در این مثال، جهت بردار از گربه به ببر و از سگ به گرگ مشابه است

- از حیوان خانگی به حیوان وحشی

- جهت بردار از سگ به گربه و از گرگ به ببر نیز مشابه است

- از خانواده سگ به خانواده گربه



# آموزش جانمایی کلمات

- یک فضای مناسب تا حد زیادی به مسئله مورد نظر بستگی دارد
- فضای مناسب برای دسته‌بندی نقد فیلم ممکن است متفاوت از فضای مناسب برای دسته‌بندی اسناد حقوقی باشد، زیرا اهمیت برخی روابط معنایی متفاوت است
- آموزش یک فضای جانمایی جدید برای هر مسئله جدید منطقی است



# لایه Embedding

- لغت‌نامه‌ای که اندیس صحیح مربوط به هر کلمه را به یک بردار معنایی نگاشت می‌کند
- این لایه، یک تانسور دوبعدی از اعداد صحیح را به عنوان ورودی می‌گیرد  
- (samples, sequence\_length)
- خروجی این لایه یک تانسور سه‌بعدی از اعداد اعشاری است  
- (samples, sequence\_length, embedding\_dimensionality)

## Listing 6.5 Instantiating an Embedding layer

```
from keras.layers import Embedding  
embedding_layer = Embedding(1000, 64)
```



**The Embedding layer takes at least two arguments: the number of possible tokens (here, 1,000: 1 + maximum word index) and the dimensionality of the embeddings (here, 64).**

# لایه Embedding

- هنگامی که یک لایه Embedding را می‌سازیم، وزن‌های آن در ابتدا تصادفی است
- در طول آموزش، این بردارهای کلمات به تدریج از طریق پس‌انتشار تنظیم می‌شوند

## Listing 6.5 Instantiating an Embedding layer

```
from keras.layers import Embedding  
embedding_layer = Embedding(1000, 64)
```



**The Embedding layer takes at least two arguments: the number of possible tokens (here, 1,000: 1 + maximum word index) and the dimensionality of the embeddings (here, 64).**

# جانمایی کلمات پیش‌آموخته

- مشابه با مفهوم شبکه‌های کانولوشنی پیش‌آموخته
  - زمانیکه داده‌های کافی برای یادگیری ویژگی‌های قدرتمند نداریم، اما انتظار داریم ویژگی‌هایی که به آن نیاز داریم نسبتاً عمومی باشند
- بجای یادگیری جانمایی کلمات به طور مشترک با مسئله مورد نظر، می‌توان بردارهای جانمایی آموخته شده برای حل یک مسئله دیگر را بارگذاری کنیم
- معمولاً با استفاده از **اطلاعات آماری** وقوع کلمات محاسبه می‌شود
  - با یا بدون استفاده از شبکه‌های عصبی
- دو مورد از معروف‌ترین و موفق‌ترین آنها Word2vec و GloVe هستند